

LAPORAN TEKNIS KOMPREHENSIF

Proses Data & Eksplorasi Dataset Citra Makanan

Proyek NutriVision — ID Tim: CC26-PSU303

Yogi Ramadhani (CDC284D6Y2231) - Data Scientist

Muhammad Dafa Alvian Ramadhani (CDCC284D6Y2233) - Data Scientist

Scope	: Gathering Data, Assessing Data, Cleaning & Preprocessing, EDA
Dataset	: Dataset Citra Makanan Indonesia (20 kelas, 11.740 gambar akhir)
Tools	: Python, Google Colab, PIL, OpenCV, pandas, matplotlib
Output Dataset	: 20 label × 587 gambar per kelas, resolusi seragam 224×224 px

1. Pendahuluan & Latar Belakang

Laporan ini mendokumentasikan seluruh tahapan proses data yang dilakukan untuk membangun dataset citra makanan berkualitas tinggi guna mendukung sistem NutriVision. NutriVision adalah sistem pengenalan bahan makanan berbasis computer vision yang bertujuan membantu pengguna mengidentifikasi jenis bahan pangan secara otomatis melalui foto.

Dataset yang digunakan merupakan gabungan dari tiga sumber publik di platform Kaggle: (1) Fruits and Vegetables Image Recognition Dataset oleh kritikseth, (2) Food Ingredients Image Dataset 2013 Bahan Makanan oleh byrux12, dan (3) Dataset Bahan Makanan Mentah oleh efanfitriyan. Ketiga dataset menggunakan label berbahasa Inggris yang kemudian diterjemahkan secara manual ke Bahasa Indonesia sebelum diproses. Proses ini mencakup empat tahapan utama: Gathering Data, Assessing Data, Cleaning & Preprocessing, serta Exploratory Data Analysis (EDA).

1.1 Permasalahan Dataset

Sebelum preprocessing dilakukan, dataset menghadapi beberapa tantangan utama yang perlu diselesaikan agar siap digunakan pada tahap modeling:

- Sumber data beragam: tiga dataset berbeda dengan konvensi penamaan dan struktur folder yang tidak seragam
- Label tidak konsisten: nama kelas dalam bahasa Inggris dan format folder bervariasi (train/test/valid)
- Distribusi data tidak seimbang: jumlah gambar per kelas sangat bervariasi, mulai dari 65 hingga 587 gambar
- Variasi ukuran gambar: resolusi gambar tidak seragam, dari gambar kecil (100×100) hingga sangat besar (7360×4912 piksel)
- Data duplikat: ditemukan 10 file gambar yang identik lintas folder
- Label berlebih: 17 label dengan jumlah data sangat sedikit yang dapat merusak kualitas model

1.2 Pertanyaan Bisnis

Proses analisis dalam laporan ini menjawab tiga pertanyaan bisnis utama:

1. Bagaimana mengevaluasi kualitas dan kesiapan dataset citra makanan melalui analisis distribusi jumlah data per kelas, deteksi duplikasi, serta karakteristik nilai pixel setelah preprocessing untuk mendukung tahap eksplorasi data pada sistem NutriVision?
2. Bagaimana mengidentifikasi ketidakseimbangan jumlah citra antar kelas serta mengevaluasi peran augmentasi dalam menyeimbangkan distribusi data untuk meningkatkan kualitas dataset citra makanan pada tahap eksplorasi?
3. Bagaimana teknik resize dengan padding mempengaruhi distribusi nilai pixel dan representasi visual citra makanan untuk memastikan kualitas preprocessing dalam dataset NutriVision pada tahap eksplorasi data?

2. Gathering Data

Tahap pertama adalah pengumpulan dan penggabungan data dari tiga dataset Kaggle yang berbeda menjadi satu dataset terpadu. Data diunduh dari Kaggle, disimpan di Google Drive, lalu diproses menggunakan Python di Google Colab. Translasi nama label dari bahasa Inggris ke Bahasa Indonesia dilakukan secara manual di Google Drive sebelum penggabungan dilakukan.

2.1 Sumber Data

Dataset dikumpulkan dari tiga sumber publik di platform Kaggle. Ketiga dataset memiliki label dalam bahasa Inggris yang kemudian diterjemahkan secara manual ke Bahasa Indonesia sebelum proses penggabungan.

#	Nama Dataset	Kaggle URL	Folder Lokal	Deskripsi
1	Fruits and Vegetables Image Recognition Dataset	kaggle.com/datasets/kritikseth/fruit-and-vegetable-image-recognition	dataset buah sayur	Dataset buah dan sayuran dengan struktur folder train/test/valid, berisi gambar berbagai jenis buah dan sayuran, ~35 kelas dengan 65–100 gambar per kelas
2	Food Ingredients Image Dataset – Bahan Makanan	kaggle.com/datasets/byrux12/ingredients-bahan-makanan-image-gambar	dataset makanan	Dataset bahan makanan Indonesia yang sudah cukup bersih, 8 kelas utama dengan ~500 gambar per kelas (cabai, tomat, bawang, dll)
3	Dataset Bahan Makanan Mentah	kaggle.com/datasets/efanfitriyan/dataset-bahan-makanan-mentah	dataset mentah	Dataset bahan makanan mentah Indonesia, 8 kelas protein hewani dan nabati (daging, ikan, udang, tempe, tahu, dll) dengan ~500 gambar per kelas

Catatan penting: Ketiga dataset menggunakan label bahasa Inggris (misalnya 'garlic', 'chilli pepper', 'cabbage').

Translasi label ke Bahasa Indonesia dilakukan secara manual di Google Drive sebelum proses penggabungan.

Contoh: 'garlic' → 'bawang putih', 'chilli pepper' → 'cabai', 'cabbage' → 'kubis'

2.2 Strategi Penggabungan

Penggabungan dilakukan dengan pendekatan yang terstruktur untuk memastikan integritas data. Berikut adalah alur logika yang diterapkan:

Untuk setiap file gambar di semua folder sumber:

1. Hitung hash MD5 file → identifikasi duplikat sejak awal
2. Ekstrak label dari path folder (abaikan: train/test/valid/val)

3. Buat folder label di direktori target
4. Rename file: format '{label}_{index}.jpg'
5. Salin file jika hash belum ada dalam set hash_seen

Pendekatan penamaan ulang file dengan format label_index.jpg dilakukan untuk menghindari konflik nama file antar sumber data. Penggunaan hash MD5 sejak tahap ini juga membantu mengurangi duplikat sejak awal proses.

2.3 Hasil Gathering Data

Setelah proses penggabungan selesai, total gambar yang berhasil dikumpulkan dari ketiga sumber Kaggle adalah:

Sumber Dataset (Kaggle)	Folder Lokal	Kelas Utama	Estimasi Gambar
efanfitriyan/dataset-bahan-makanan-mentah	dataset mentah	Daging sapi, daging ayam, udang, ikan, tempe, tahu, telur, bawang	~4.000 gambar
byrux12/ingredients-bahan-makanan-image-gambar	dataset makanan	Cabai, tomat, bawang merah, bawang putih, durian, ikan, tempe, tahu	~4.000 gambar
kritikseth/fruit-and-vegetable-image-recognition	dataset buah sayur	35+ kelas buah dan sayuran (apel, pisang, kiwi, lemon, wortel, dll)	~619 gambar

Total gambar berhasil digabung: 8.617 gambar
Metode deduplication: Hash MD5 untuk mendeteksi file identik
Direktori output: dataset_capstone_raw (sebelum cleaning)

3. Assessing Data

Tahap assessing (penilaian data) dilakukan untuk memahami kondisi aktual dataset sebelum proses pembersihan. Empat aspek utama yang diperiksa adalah: jumlah gambar per label, validitas file, duplikasi, dan ukuran gambar.

3.1 Distribusi Jumlah Gambar per Label

Pemeriksaan distribusi gambar per kelas bertujuan untuk mengidentifikasi ketidakseimbangan data yang berpotensi memengaruhi performa model. Berikut distribusi lengkap dataset raw:

Label	Jumlah Gambar	Status
cabai	587	Tertinggi (acuan balancing)
tomat	579	Sangat tinggi
daging sapi	500	Tinggi
udang	500	Tinggi
bawang putih	499	Tinggi
ikan	494	Tinggi
tempe	490	Tinggi
durian	487	Tinggi
daging ayam	481	Tinggi
tahu	474	Sedang
telur	454	Sedang
bawang merah	431	Sedang
jagung	154	Rendah
paprika	169	Rendah
... (label buah sayur)	65–100	Sangat rendah

Total label pada dataset raw: 37 label. Ketimpangan distribusi sangat signifikan — kelas cabai memiliki 587 gambar sementara kelas jahe dan jeruk hanya memiliki 65 gambar. Rasio ketimpangan mencapai 1:9, yang dapat menyebabkan model bias terhadap kelas mayoritas.

Ketimpangan distribusi seperti ini perlu segera ditangani sebelum modeling dilakukan, karena Johnson & Khoshgoftaar (2019) menunjukkan bahwa rasio ketidakseimbangan kelas yang melebihi 4:1 secara konsisten menurunkan performa model pada kelas minoritas, dan merekomendasikan strategi resampling atau augmentasi sebagai solusi utama.

3.2 Validitas File (Corrupt Check)

Pemeriksaan dilakukan dengan membuka dan memuat setiap file gambar menggunakan library PIL. Hasil pemeriksaan:

Metrik	Hasil
Total file diperiksa	8.150 file
File valid (dapat dibuka)	8.150 file (100%)
File tidak valid / corrupt	0 file (0%)
Format yang diperiksa	.jpg, .jpeg, .png

Dataset bebas dari file corrupt. Seluruh file dapat dibuka dan dimuat dengan benar oleh PIL.

3.3 Deteksi Duplikasi

Deteksi duplikasi dilakukan menggunakan perbandingan hash MD5 antar file. Dua file disebut duplikat jika nilai hash-nya identik (konten gambar yang sama persis, terlepas dari nama file).

MD5 dipilih karena menghasilkan hash 128-bit yang unik untuk setiap konten file — dua file dengan byte identik selalu menghasilkan hash yang sama, terlepas dari nama filenya (Rivest, 1992). Pendekatan hash-based deduplication ini efisien untuk pipeline data skala besar karena beroperasi pada kompleksitas $O(n)$ linear tanpa memerlukan perbandingan berpasangan antar file.

Hasil deteksi menemukan 10 file duplikat, seluruhnya berada pada folder bawang_putih dengan pola nama 'Salinan garlic_XXXXX.jpg'. Nama file masih menggunakan bahasa Inggris ('garlic') karena berasal langsung dari dataset Kaggle kritikseth/fruit-and-vegetable-image-recognition yang belum diterjemahkan penamaannya. Prefiks 'Salinan' mengindikasikan file disalin secara manual dari sumber yang sama sebelum dimasukkan ke Google Drive.

Total duplikat ditemukan: 10 file

Label terdampak: bawang_putih (Salinan garlic_16086.jpg s/d Salinan garlic_16095.jpg)

Penyebab: file disalin secara manual dari dataset sumber

3.4 Pemeriksaan Ukuran Gambar

Pemeriksaan ukuran gambar bertujuan mendeteksi gambar yang terlalu kecil (< 50px) sehingga terlalu rendah kualitasnya, dan gambar yang terlalu besar (> 2000px) yang memerlukan resize.

Kategori	Threshold	Jumlah Ditemukan
Gambar terlalu kecil	width atau height < 50 px	0 gambar
Gambar terlalu besar	width atau height > 2000 px	412 gambar
Gambar normal	50px – 2000px	7.738 gambar

412 gambar dengan resolusi di atas 2000px perlu di-resize. Contoh gambar berukuran sangat besar mencakup gambar tomat dengan resolusi hingga 3872×2592 dan ikan dengan resolusi hingga 3456×5184 piksel.

4. Cleaning & Preprocessing

Tahap cleaning dan preprocessing terdiri dari empat langkah berurutan: membuat salinan folder kerja, menghapus label tidak diperlukan, menghapus data duplikat, melakukan augmentasi untuk balancing, dan resize gambar ke ukuran seragam.

4.1 Pembuatan Folder Kerja

Sebelum melakukan modifikasi apapun, data mentah (dataset_capstone_raw) disalin ke folder baru (dataset_raw_clean). Tujuannya adalah menjaga integritas data asli sehingga proses before vs after dapat dibandingkan dengan jelas dan pipeline data dapat di-reproduce.

```
raw_path      = /DATASET CITRA MAKANAN/dataset_capstone_raw
processed_path = /DATASET CITRA MAKANAN/dataset_raw_clean
shutil.copytree(raw_path, processed_path, dirs_exist_ok=True)
```

Prinsip ini mengikuti best practice data science: tidak pernah memodifikasi data asli secara langsung, selalu bekerja pada salinan.

Wickham & Grolemund (2017) menegaskan bahwa immutability data mentah adalah fondasi pipeline yang reproducible — setiap transformasi harus dapat diulang dari titik awal tanpa kehilangan data asli. Hal ini juga selaras dengan prinsip MLOps modern yang mengutamakan versioning dan traceability (Sculley et al., 2015).

4.2 Penghapusan Label Tidak Diperlukan

17 label dihapus dari dataset. Pertimbangan penghapusan didasarkan pada bahan makanan umum saja yang dipakai dan jumlah data yang sangat sedikit (di bawah threshold yang dianggap memadai untuk training model yang robust) dan relevansi dengan kebutuhan sistem NutriVision.

Model dengan data di bawah ~100 sampel per kelas cenderung mengalami underfitting karena tidak mampu mempelajari fitur diskriminatif yang memadai (Banko & Brill, 2001). Dalam praktik computer vision, Shorten & Khoshgoftaar (2019) merekomendasikan minimal 50–100 sampel per kelas sebelum augmentasi sebagai threshold kelayakan — sehingga kelas dengan data di bawah batas ini lebih baik dihapus daripada dipertahankan dan menghasilkan prediksi yang tidak dapat diandalkan.

Label yang dihapus:

Label Dihapus	Jumlah Gambar	Alasan
semangka, lobak, kedelai, kentang, delima, bayam	75–95	Data terlalu sedikit untuk modeling
jagung, kacang polong, pir, paprika	92–169	Data sedikit, relevansi rendah
jeruk, anggur, terong, kembang kol, bit, jahe, mangga	65–95	Data minimal, potensi underfitting

Label tersisa setelah penghapusan: 20 label

Penghapusan dilakukan dengan `shutil.rmtree()` secara permanen pada folder processed

Evidence: dataset akhir hanya berisi 20 kelas yang relevan dan memiliki data cukup

4.3 Penghapusan Data Duplikat

Setelah pembersihan label, penghapusan duplikat dilakukan sekali lagi pada dataset yang sudah dibersihkan. Metode yang digunakan identik dengan tahap assessing: membandingkan hash MD5 antar file dan menghapus file yang memiliki hash yang sudah pernah muncul.

Metrik	Nilai
Total duplikat ditemukan	10 file
Total duplikat dihapus	10 file
Sisa duplikat setelah pembersihan	0 file
Penurunan duplikat	100%

Pembersihan duplikat penting untuk memastikan bahwa tidak ada gambar yang dilatih lebih dari sekali, yang akan menyebabkan model mempelajari pola yang sama berulang kali (data leakage dalam konteks pelatihan).

Sebagaimana ditunjukkan oleh Kapoor & Narayanan (2023), data leakage akibat duplikat menyebabkan model menghafal contoh tertentu alih-alih belajar generalisasi, menghasilkan evaluasi performa yang overestimated secara signifikan. Deteksi berbasis hash kriptografis merupakan metode deterministik yang efisien untuk identifikasi konten identik terlepas dari nama file (Broder, 1997).

4.4 Augmentasi untuk Class Balancing

Augmentasi data dilakukan untuk menyeimbangkan jumlah gambar pada setiap kelas. Target balancing ditetapkan berdasarkan kelas dengan jumlah gambar terbanyak, yaitu cabai dengan 587 gambar. Semua kelas lain ditambahkan gambar augmentasi hingga mencapai angka 587.

Shorten & Khoshgoftaar (2019) merekomendasikan oversampling berbasis augmentasi sebagai strategi yang lebih baik dibanding undersampling untuk dataset citra, karena pendekatan ini mempertahankan seluruh data asli sambil meningkatkan volume kelas minoritas. Strategi menyamakan jumlah ke kelas terbesar (oversampling to majority) terbukti efektif mengeliminasi bias model terhadap kelas mayoritas.

4.4.1 Teknik Augmentasi yang Digunakan

Fungsi augmentasi menerapkan tiga transformasi secara acak pada setiap gambar:

- Random Flip Horizontal (probabilitas 50%) — membalik gambar secara horizontal untuk menambah variasi orientasi
- Random Rotation — rotasi gambar pada sudut 90°, 180°, atau 270° secara acak untuk invariansi orientasi
- Random Brightness Adjustment — penyesuaian kecerahan gambar pada faktor antara 0.7 hingga 1.3 untuk mensimulasikan kondisi pencahayaan yang bervariasi

Kombinasi tiga teknik augmentasi ini dipilih karena relevan secara visual — gambar bahan makanan pada dunia nyata dapat difoto dari berbagai sudut, orientasi, dan kondisi cahaya yang berbeda.

Ketiga teknik ini memiliki landasan empiris yang kuat dalam literatur augmentasi citra (Shorten & Khoshgoftaar, 2019): horizontal flip adalah transformasi paling umum dan aman untuk objek tanpa orientasi asimetris semantis; rotasi 90°/180°/270° efektif untuk dataset di mana objek dapat muncul dari berbagai sudut pandang; dan brightness jitter mensimulasikan variasi pencahayaan nyata, meningkatkan robustness model terhadap kondisi foto yang beragam.

4.4.2 Hasil Balancing

Label	Sebelum Augmentasi	Sesudah Augmentasi	Gambar Ditambahkan
apel	71	587	516
pisang	73	587	514
lemon	76	587	511
kiwi	84	587	503
kubis	82	587	505
timun	86	587	501
selada	92	587	495
wortel	78	587	509
bawang merah	431	587	156
telur	454	587	133
tahu	474	587	113
tempe	490	587	97
... (kelas besar)	480–579	587	8–107
cabai (referensi)	587	587	0

Total gambar sebelum augmentasi: 6.608 gambar
 Total gambar setelah augmentasi: 11.740 gambar
 Peningkatan volume data: +77.7% dari dataset asli
 Semua kelas kini memiliki tepat 587 gambar (fully balanced)

4.5 Resize dengan Padding

Seluruh gambar di-resize menjadi ukuran seragam 224×224 piksel. Ukuran ini dipilih karena kami menggunakan model CNN dan merupakan standar input untuk sebagian besar arsitektur CNN modern seperti ResNet, MobileNet, dan EfficientNet.

Ukuran 224×224 piksel merupakan standar input yang digunakan oleh arsitektur-arsitektur CNN paling berpengaruh: ResNet (He et al., 2016), MobileNet (Howard et al., 2017), dan EfficientNet-B0 (Tan & Le, 2019). Konsistensi ini menjadikan 224×224 sebagai pilihan yang paling kompatibel untuk transfer learning dan meminimalkan kebutuhan penyesuaian tambahan saat mengadopsi pre-trained model.

4.5.1 Algoritma Resize with Padding

Berbeda dengan resize biasa yang dapat merusak aspek rasio gambar, teknik resize with padding mempertahankan proporsi asli gambar. Algoritmanya adalah:

```
def resize_with_padding(img, size=224):
    h, w = img.shape[:2]
    scale = size / max(h, w)          # skala agar sisi terpanjang = 224
    new_w = int(w * scale)
    new_h = int(h * scale)
    resized = cv2.resize(img, (new_w, new_h))
```

```
mean_color = img.mean(axis=(0,1)) # warna rata-rata gambar
canvas = np.ones((224, 224, 3)) * mean_color # background = mean color
# tempel gambar di tengah canvas
x_offset = (224 - new_w) // 2
y_offset = (224 - new_h) // 2
canvas[y_offset:y_offset+new_h, x_offset:x_offset+new_w] = resized
return canvas
```

Keunggulan teknik ini dibanding simple resize: objek makanan tidak terdistorsi karena aspek rasio tetap dipertahankan. Area padding diisi dengan warna rata-rata gambar (bukan warna hitam/putih polos) sehingga transisi antara objek dan padding lebih natural dan tidak menciptakan artefak tajam yang dapat membingungkan model.

Squash resize tanpa mempertahankan aspek rasio memperkenalkan distorsi geometri yang dapat menurunkan akurasi model, khususnya pada objek dengan bentuk khas seperti ikan atau udang (Koonce, 2021). Penggunaan warna rata-rata sebagai area padding dipilih karena meminimalkan perbedaan statistik distribusi pixel antara objek dan latar, sehingga model tidak mempelajari artefak padding sebagai fitur palsu — suatu permasalahan yang juga diidentifikasi oleh Simonyan & Zisserman (2014) dalam studi arsitektur VGGNet.

4.5.2 Hasil Resize

Seluruh 11.740 gambar berhasil di-resize ke 224×224 piksel. Kondisi gambar setelah resize:

Kondisi	Status
Ukuran gambar	Seragam 224×224 px untuk semua gambar
Aspek rasio	Dipertahankan (tidak terdistorsi)
Area padding	Diisi warna rata-rata gambar
Posisi objek	Di tengah canvas
Format output	JPEG (overwrite file lama)

4.6 Dataset Splitting

Setelah seluruh tahap preprocessing selesai, dataset akhir yang terdiri dari 11.740 gambar (20 kelas × 587 gambar per kelas) dibagi menjadi tiga subset menggunakan stratified split: train, validation, dan test. Stratified split digunakan untuk memastikan setiap subset memiliki proporsi kelas yang merata, sehingga tidak ada kelas yang overrepresented atau underrepresented pada salah satu subset.

4.6.1 Rasio Pembagian Dataset

Dataset dibagi dengan rasio 70:20:10 sebagai berikut:

Subset	Proporsi	Per Kelas	Total Gambar	Fungsi
Train	70%	410 gambar	8.200 gambar	Melatih parameter model
Validation	20%	117 gambar	2.340 gambar	Monitoring performa saat training & tuning hyperparameter
Test	10%	60 gambar	1.200 gambar	Evaluasi akhir performa model (data tak terlihat)

TOTAL	100%	587 gambar	11.740 gambar	—
--------------	-------------	-------------------	----------------------	----------

Penggunaan stratified split memastikan bahwa setiap subset (train, validation, test) memiliki komposisi kelas yang identik secara proporsional. Hal ini krusial untuk evaluasi model yang valid dan tidak bias. Tanpa stratifikasi, split acak dapat menghasilkan subset test yang tidak merepresentasikan seluruh kelas secara merata, sehingga metrik evaluasi menjadi tidak reliabel (Kapoor & Narayanan, 2023).

4.6.2 Alasan Pemilihan Rasio 70:20:10

Rasio 70:20:10 dipilih berdasarkan beberapa pertimbangan:

- Train 70% (8.200 gambar): Porsi terbesar digunakan untuk melatih model agar dapat mempelajari fitur visual dari masing-masing kelas bahan makanan. Dengan 410 gambar per kelas untuk training, model memiliki cukup sampel untuk konvergensi yang stabil.
- Validation 20% (2.340 gambar): Digunakan selama proses training untuk memantau performa model pada data yang tidak dilihat saat pelatihan, serta sebagai dasar pengambilan keputusan tuning hyperparameter. Porsi 20% memberikan 117 gambar per kelas, yang cukup untuk menghasilkan estimasi loss dan akurasi validasi yang representatif.
- Test 10% (1.200 gambar): Digunakan satu kali di akhir proses training sebagai evaluasi final performa model. Data test tidak pernah dilihat oleh model selama proses pelatihan maupun tuning, sehingga hasil evaluasinya mencerminkan kemampuan generalisasi model yang sesungguhnya. Dengan 60 gambar per kelas, subset test tetap representatif untuk seluruh 20 kelas.

5. Exploratory Data Analysis (EDA)

EDA dilakukan setelah preprocessing selesai untuk memverifikasi kualitas dataset dan menjawab tiga pertanyaan bisnis yang telah dirumuskan. Analisis mencakup distribusi data, deteksi duplikasi final, statistik pixel, serta evaluasi kualitas preprocessing resize dan padding.

5.1 Pertanyaan Bisnis 1: Kualitas dan Kesiapan Dataset

Evaluasi kualitas dataset dilakukan melalui tiga dimensi: distribusi per kelas, duplikasi, dan karakteristik pixel.

5.1.1 Distribusi Data Setelah Balancing


Seluruh 20 kelas memiliki tepat 587 gambar. Distribusi 100% seimbang.

Label	Jumlah Gambar	Label	Jumlah Gambar
daging sapi	587	lemon	587
durian	587	kiwi	587
daging ayam	587	apel	587
tomat	587	wortel	587
bawang putih	587	udang	587
bawang merah	587	telur	587
ikan	587	kubis	587
pisang	587	timun	587
cabai	587	selada	587
tempe	587	tahu	587

Insight: Dataset telah memiliki distribusi yang sepenuhnya merata. Tidak ada kelas mayoritas maupun minoritas. Keseragaman ini memastikan model tidak bias terhadap kelas tertentu dan setiap kategori makanan memiliki representasi yang setara dalam proses training.

5.1.2 Verifikasi Duplikasi Final

Kondisi	Jumlah Duplikat
Sebelum preprocessing	10 file
Setelah preprocessing	0 file
Penurunan	100%




5.1.3 Statistik Nilai Pixel

Statistik nilai pixel dihitung dari sampel acak 100 gambar setelah preprocessing:

Statistik	Nilai	Interpretasi
Minimum	0	Pixel gelap (hitam) tersedia — variasi cukup
Maksimum	255	Pixel terang (putih) tersedia — range penuh
Mean	131.76	Distribusi relatif seimbang (ideal: 128)
Std Deviasi	87.46	Variasi cukup tinggi — gambar beragam

Nilai mean mendekati 128 (tengah skala 0–255) menunjukkan distribusi pixel yang seimbang antara gambar gelap dan terang. Standar deviasi 87.46 menunjukkan adanya variasi visual yang cukup, yang merupakan kondisi baik untuk training model yang generalisasi.




5.2 Pertanyaan Bisnis 2: Ketidakseimbangan & Peran Augmentasi

5.2.1 Analisis Ketidakseimbangan Sebelum Augmentasi

Kelompok Kelas	Rentang Jumlah	Kelas
Kelas Besar (>450)	454–587	cabai, tomat, daging sapi, udang, bawang putih, ikan, tempe, durian, daging ayam, tahu, telur, bawang merah
Kelas Sedang (100–450)	154–431	jagung, paprika
Kelas Kecil (<100)	65–95	apel, lemon, pisang, kiwi, kubis, wortel, timun, selada, dan lainnya


Rasio ketimpangan maksimum: 587 (cabai) vs 65 (jahe/jeruk) = 9:1. Tanpa balancing, model cenderung bias dan performa pada kelas kecil akan jauh lebih buruk.



5.2.2 Evaluasi Peran Augmentasi

Metrik	Sebelum Augmentasi	Setelah Augmentasi
Total gambar	6.608	11.740
Min gambar per kelas	71 (apel)	587 (semua kelas)
Max gambar per kelas	587 (cabai)	587 (semua kelas)
Std deviasi distribusi	Sangat tinggi	0 (sempurna seimbang)
Rasio ketimpangan	8.3:1	1:1

Augmentasi berhasil sepenuhnya mengeliminasi ketidakseimbangan kelas. Volume data meningkat 77.7% dari 6.608 menjadi 11.740 gambar. Teknik yang digunakan (flip, rotasi, brightness) dipilih karena relevan secara semantis — gambar bahan makanan memang dapat muncul dalam berbagai orientasi dan kondisi cahaya pada dunia nyata.



5.3 Pertanyaan Bisnis 3: Kualitas Preprocessing Resize & Padding


Analisis kualitas preprocessing dilakukan per label menggunakan metrik: persentase padding, brightness rata-rata, standar deviasi pixel, serta mean channel warna R, G, B.

5.3.1 Analisis Padding

pad_mean = 0.0 dan pad_max = 0.0 untuk SEMUA label.

Ini berarti semua gambar setelah preprocessing SUDAH berukuran 224×224 piksel.
Tidak ada area padding yang tersisa — gambar telah sepenuhnya mengisi canvas.

Hasil `pad_pct = 0` untuk semua gambar menunjukkan bahwa proses `resize` telah berjalan dengan sempurna. Gambar asli yang memiliki aspek rasio persegi (seperti gambar tempe dan tahu dari dataset mentah 256×256) langsung diubah menjadi 224×224 tanpa padding.



5.3.2 Analisis Karakteristik Warna per Label

Label	Brightness	Std Pixel	Mean R	Mean G	Mean B	Interpretasi Warna Dominan
daging ayam	184.91	71.14	203.72	183.25	167.76	Terang kekuningan (daging mentah/matang)
bawang putih	168.66	68.77	184.75	171.15	150.09	Terang putih keabu-abuan
udang	165.68	52.05	165.67	181.21	150.15	Terang, dominan hijau-kemerahan
tahu	158.07	87.71	189.13	174.92	110.16	Kuning muda
tempe	150.99	86.58	166.94	155.95	130.07	Kecoklatan
selada	107.67	63.28	112.96	134.66	75.39	Gelap, dominan hijau (sayuran)
apel	118.42	65.65	138.75	115.96	100.55	Campuran merah-hijau
ikan	124.02	44.11	124.64	127.17	120.26	Netral abu-abu (daging ikan)

Pola warna per label sangat konsisten dengan karakteristik visual bahan makanan di dunia nyata: sayuran (selada, kubis, timun) memiliki brightness rendah dan dominan hijau, sementara bahan protein putih (daging ayam, bawang putih) memiliki brightness tinggi. Konsistensi ini membuktikan bahwa preprocessing tidak merusak informasi warna yang penting untuk klasifikasi.

6. Ringkasan Pipeline & Perbandingan Before-After

Tahap	Kondisi Awal	Kondisi Akhir	Perubahan
Jumlah label	37 label	20 label	-17 label dihapus
Total gambar	8.617 gambar	11.740 gambar	+3.123 gambar (augmentasi)
File corrupt	0 file	0 file	Tidak ada perubahan
File duplikat	10 file	0 file	-10 file dihapus
Distribusi kelas	Tidak seimbang (71–587)	Seimbang (587 semua)	Rasio 9:1 → 1:1
Ukuran gambar	Beragam (100px–7360px)	Seragam 224×224 px	Fully standardized
Non-image files	0 file	0 file	Dataset bersih
Gambar terlalu kecil	0 gambar	0 gambar	Tidak ada
Gambar terlalu besar	412 gambar	0 gambar	-412 (sudah di-resize)

7. Kesimpulan

Berdasarkan seluruh proses yang telah dilakukan, berikut kesimpulan utama dari analisis data dan preprocessing dataset NutriVision:

7.1 Kualitas Dataset

- Dataset akhir memiliki kualitas yang sangat baik: bebas dari file corrupt, bebas duplikat, dan memiliki distribusi seimbang.
- Statistik pixel (mean 131.76, std 87.46) menunjukkan karakteristik gambar yang sehat dan beragam, tidak terdistorsi oleh preprocessing.
- Informasi warna per kelas konsisten dengan karakteristik visual bahan makanan nyata, membuktikan preprocessing tidak merusak fitur penting.

7.2 Efektivitas Augmentasi

- Augmentasi berhasil menyeimbangkan dataset dari rasio ketimpangan 9:1 menjadi 1:1 secara sempurna.
- Teknik augmentasi (flip, rotasi, brightness) yang dipilih relevan secara semantis dengan variasi gambar bahan makanan di dunia nyata.
- Volume data meningkat 77.7% dari 6.608 menjadi 11.740 gambar, memberikan lebih banyak contoh latihan untuk model.

7.3 Kualitas Resize & Padding

- Teknik resize with padding berhasil menstandarisasi seluruh gambar ke 224×224 piksel tanpa distorsi aspek rasio.
- Pengisian padding dengan warna rata-rata gambar (bukan warna solid) menghasilkan transisi yang lebih natural.
- Hasil `pad_pct = 0` untuk semua gambar mengkonfirmasi bahwa proses resize berjalan sempurna.

8. Rekomendasi Action Item

Berdasarkan temuan dari proses data ini, berikut rekomendasi konkret untuk tahap selanjutnya:

8.1 Untuk Tahap Modeling

4. Gunakan dataset akhir (20 kelas × 587 gambar = 11.740 total) sebagai input training. Dataset sudah siap tanpa preprocessing tambahan.
5. Dataset telah dibagi menggunakan stratified split dengan rasio 70% train (8.200 gambar), 20% validation (2.340 gambar), dan 10% test (1.200 gambar), memastikan setiap subset memiliki representasi yang merata dari semua 20 kelas.
6. Terapkan normalisasi pixel (0–1 atau z-score normalization) saat loading data untuk training, karena model CNN umumnya lebih stabil dengan input ternormalisasi.

7. Pertimbangkan teknik augmentasi tambahan on-the-fly saat training (misalnya zoom, shear, color jitter) agar model lebih robust terhadap variasi gambar baru.

8.2 Untuk Kualitas Data

8. Lakukan periodic re-validation jika ada penambahan data baru: jalankan kembali pipeline deteksi duplikat dan corrupt check.
9. Pertimbangkan menambah kelas untuk bahan makanan yang belum terwakili (misalnya bumbu dan rempah, atau kelas makanan olahan lainnya) untuk meningkatkan cakupan sistem NutriVision.
10. Dokumentasikan sumber setiap gambar augmentasi untuk memudahkan audit data di masa mendatang.

8.3 Untuk Sistem NutriVision

11. Lakukan validasi manual (spot-check) pada subset gambar augmentasi untuk memastikan label tetap akurat setelah transformasi. Rotasi 180° pada gambar 'bawang merah' misalnya tidak mengubah labelnya, tetapi perlu dikonfirmasi.
12. Simpan metadata dataset (jumlah per kelas, hash MD5 setiap file) sebagai referensi untuk reproducibility dan versioning dataset.

Referensi Sumber Dataset

Berikut adalah referensi lengkap ketiga dataset Kaggle yang digunakan sebagai sumber data dalam proyek NutriVision:

No.	Nama Dataset	Penulis / Uploader	Platform	URL	Akses
1	Fruits and Vegetables Image Recognition Dataset	kritikseth	Kaggle	kaggle.com/datasets/kritikseth/fruit-and-vegetable-image-recognition	Publik
2	Food Ingredients Image Dataset – Bahan Makanan	byrux12	Kaggle	kaggle.com/datasets/byrux12/ingredients-bahan-makanan-image-gambar	Publik
3	Dataset Bahan Makanan Mentah	efanfitriyan	Kaggle	kaggle.com/datasets/efanfitriyan/dataset-bahan-makanan-mentah	Publik

Catatan penggunaan dataset:

- Dataset 1 (kritikseth) menyediakan gambar buah dan sayuran dengan struktur folder train/test/valid. Label asli dalam bahasa Inggris (contoh: 'apple', 'banana', 'carrot') diterjemahkan ke 'apel', 'pisang', 'wortel'.
- Dataset 2 (byrux12) menyediakan gambar bahan makanan Indonesia yang sudah relatif bersih dengan 8 kelas (~500 gambar/kelas). Label seperti 'chilli pepper', 'garlic', 'onion' diterjemahkan ke 'cabai', 'bawang putih', 'bawang merah'.
- Dataset 3 (efanfitriyan) menyediakan gambar bahan makanan mentah khas Indonesia (daging, protein hewani, dan nabati). Label dalam bahasa Inggris juga diterjemahkan secara manual.
- Seluruh dataset bersifat publik dan dapat diakses bebas di platform Kaggle untuk keperluan riset dan edukasi.

Referensi Akademik

- Banko, M., & Brill, E. (2001). Scaling to Very Very Large Corpora for Natural Language Disambiguation. Proceedings of the 39th Annual Meeting of the Association for Computational Linguistics (ACL), 26–33.
- Broder, A.Z. (1997). On the resemblance and containment of documents. Proceedings of Compression and Complexity of Sequences, 21–29. IEEE.

- He, K., Zhang, X., Ren, S., & Sun, J. (2016). Deep Residual Learning for Image Recognition. *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, 770–778.
- Howard, A.G., Zhu, M., Chen, B., Kalenichenko, D., Wang, W., Weyand, T., Andreetto, M., & Adam, H. (2017). MobileNets: Efficient Convolutional Neural Networks for Mobile Vision Applications. *arXiv preprint arXiv:1704.04861*.
- Johnson, J.M., & Khoshgoftaar, T.M. (2019). Survey on deep learning with class imbalance. *Journal of Big Data*, 6(1), Article 27. Springer.
- Kapoor, A., & Narayanan, A. (2023). Leakage and the Reproducibility Crisis in Machine Learning-based Science. *Patterns*, 4(9), 100804. Cell Press.
- Koonce, B. (2021). *Convolutional Neural Networks with Swift for TensorFlow: Image Recognition and Dataset Categorization*. Apress.
- Rivest, R. (1992). The MD5 Message-Digest Algorithm. RFC 1321. Internet Engineering Task Force (IETF).
- Sculley, D., Holt, G., Golovin, D., Davydov, E., Phillips, T., Ebner, D., Chaudhary, V., Young, M., Crespo, J.-F., & Dennison, D. (2015). Hidden Technical Debt in Machine Learning Systems. *Advances in Neural Information Processing Systems (NeurIPS)*, 28, 2503–2511.
- Shorten, C., & Khoshgoftaar, T.M. (2019). A survey on Image Data Augmentation for Deep Learning. *Journal of Big Data*, 6(1), Article 60. Springer.
- Simonyan, K., & Zisserman, A. (2014). Very Deep Convolutional Networks for Large-Scale Image Recognition. *arXiv preprint arXiv:1409.1556*. Published at ICLR 2015.
- Tan, M., & Le, Q. (2019). EfficientNet: Rethinking Model Scaling for Convolutional Neural Networks. *Proceedings of the 36th International Conference on Machine Learning (ICML)*, PMLR 97, 6105–6114.
- Wickham, H., & Grolemund, G. (2017). *R for Data Science: Import, Tidy, Transform, Visualize, and Model Data*. O'Reilly Media.